



LOTUS AI
YAPAY ZEKA VE BİLİŞİM ÇÖZÜMLERİ A.Ş.

5ML Projesi

Python Kodları

Uygar Görmez

***Nişantaşı Üniversitesi Bilgisayar
Mühendisliği 4.sınıf Öğrencisi***

LOTUS AI KASIM-OCAK DÖNEMİ STAJERİ

Proje: Gıda Resimlerini Sınıflandırma (Derin Öğrenme - CNN)

Proje Konusu ve Veri Seti

Bu çalışmada, bilgisayarlı görü (computer vision) teknikleri kullanılarak yemek resimlerinin hangi sınıfa ait olduğunu tahmin eden bir derin öğrenme modeli geliştirilmiştir. Analizde, dünya çapında standart kabul edilen "Food-101" veri setinin bir bölümü kullanılmıştır.

1. Business Understanding (İşin Anlaşılması)

Problem: Market veri tabanına binlerce ürün girilmektedir. Ürünlerin kategorilerini (Gıda, Temizlik, İçecek vb.) manuel seçmek zaman alıcıdır ve hataya açıktır.

Hedef: Bir ürünün sadece PRICE (Satış Fiyatı) ve AMOUNT (Satılan Miktar) bilgilerine bakarak, hangi ana kategoride yer aldığını otomatik tahmin eden bir yapay zeka modeli geliştirmektir.

2. Data Understanding (Verinin Anlaşılması)

Veri Seti: MarketSales verisi kullanılmıştır.

Odak: Veri setinde işlem hacmi en yüksek olan 5 ana kategori (GIDA, KAĞIT, MEYVE SEBZE, SÜT KAHVALTILIK, İÇECEK) analiz kapsamına alınmıştır.

Girdi Değişkenleri: Fiyat ve Miktar.

Hedef Değişken: Kategori İsmi.

3. Data Preparation (Veri Hazırlığı)

Kodlama (Encoding): Makine öğrenmesi algoritmaları metinle çalışmadığı için, kategori isimleri Label Encoder kullanılarak sayısal değerlere dönüştürülmüştür.

Eğitim/Test Ayrımı: Verinin %80'i modelin öğrenmesi, %20'si ise test edilmesi için ayrılmıştır.

4. Modeling (AutoML Yaklaşımı)

Yöntem: En iyi sonucu bulmak için Decision Tree, Random Forest ve Gradient Boosting algoritmaları AutoML mantığıyla yarışdırılmıştır.

Optimizasyon: RandomizedSearchCV kullanılarak her modelin en iyi parametreleri (ağaç derinliği, yaprak sayısı vb.) bilgisayar tarafından otomatik denenmiştir.

5. Evaluation (Değerlendirme)

Kazanan Model: Yapılan yarışma sonucunda Random Forest (Rastgele Orman) algoritması en yüksek başarıyı vermiştir.


Başarı Oranı: Modelimiz %56.6 doğruluk (Accuracy) oranına ulaşmıştır.

Confusion Matrix (Karmaşıklık Matrisi) Yorumu:

Grafikteki koyu lacivert alan (GIDA kategorisi), modelin en iyi tahmin ettiği sınıftır (347 doğru tahmin).

Meyve-Sebze ve Süt-Kahvaltılık kategorilerinde de modelin doğru tahminleri (köşegen üzerindeki kutular) belirgindir.

Hataların çoğu, fiyat aralıkları birbirine çok benzeyen ürünlerde (Örn: Ucuz gıda ürünleri ile ucuz kahvaltılıklar) gerçekleşmiştir.



6. Deployment (Dağıtım)

Bu model, yeni ürün giriş ekranına entegre edilebilir. Personel fiyatı girdiğinde sistem; "Bu ürün fiyatına göre %70 ihtimalle GIDA kategorisindedir, seçmek ister misiniz?" şeklinde bir öneri sunarak iş sürecini hızlandırabilir.

Proje: Satış Miktarı Tahmini (Regresyon Analizi)

Proje Konusu ve Veri Seti

Bu projede, market satış verilerini kullanarak ürünlerin birim fiyatları ile satış miktarları (arasındaki ilişkiyi analiz ettim. Amacım, fiyat değişimlerinin satış hacmi üzerindeki etkisini modellemek ve gelecekteki satış miktarlarını tahmin etmektir. Analizde "MarketSales.xlsx" veri seti kullanılmıştır

1. Business Understanding (İşin Anlaşılması)

Problem: Market stok yönetiminde, hangi üründen kaç adet satılacağını önceden kestirmek stok maliyetlerini düşürmek için kritiktir.

Hedef: Geçmiş satış verilerini kullanarak satış miktarını (AMOUNT) tahmin eden bir makine öğrenmesi modeli geliştirmek.

```
--- 1. ADIM: Dosya Aranıyor ve Yükleniyor ---  
✅ Dosya bulundu: '../MarketSales.xlsx'  
🌟 Veri başarıyla hafızaya alındı!  
  
--- 2. ADIM: Veri Temizleniyor ve Hazırlanıyor ---  
✅ Veri Hazır! Eğitim için 575551 satır kullanılacak.  
  
--- 3. ADIM: AutoML Başlıyor (En iyi model aranıyor...) ---  
🕒 Linear Regression modeli deneniyor...  
-> R2 Başarısı: 0.0335  
🕒 Random Forest modeli deneniyor...  
-> R2 Başarısı: 0.0741  
🕒 Gradient Boosting modeli deneniyor...  
-> R2 Başarısı: 0.0643  
  
🏆 KAZANAN MODEL: Random Forest  
🌟 En Yüksek R2 Skoru: 0.0741  
  
--- 4. ADIM: Sonuçlar Görselleştiriliyor ---
```

2. Data Understanding (Verinin Anlaşılması)

Veri Seti: MarketSales verisi kullanılmıştır.

Boyut: Eğitim için yaklaşık 575.000 satır veri işlenmiştir.

Öznitelikler: Modelde bağımsız değişken olarak PRICE (Fiyat), CATEGORY_NAME1 (Kategori) ve BRAND (Marka) kullanılmıştır.

3. Data Preparation (Veri Hazırlığı)

Temizleme: Eksik veriler (Null değerler) temizlenmiştir.

Dönüşüm: Kategorik değişkenler (Marka ve Kategori), makine öğrenmesi algoritmalarının anlayabileceği formata (One-Hot Encoding) dönüştürülmüştür.

Bölümleme: Veri %80 Eğitim ve %20 Test seti olarak ayrılmıştır.

4. Modeling (Modelleme & AutoML)

Yaklaşım: AutoML (Otomatik Makine Öğrenmesi) prensibiyle birden fazla algoritma yarıştırmıştır.

Kullanılan Algoritmalar: Linear Regression, Random Forest Regressor, Gradient Boosting Regressor.

Optimizasyon: RandomizedSearchCV kullanılarak her model için en iyi hiperparametreler (ağaç sayısı, derinlik vb.) otomatik aranmıştır.

5. Evaluation (Değerlendirme)


Karşılaştırma Sonuçları:

Linear Regression R2 Skoru: 0.0335

Gradient Boosting R2 Skoru: 0.0643

Random Forest R2 Skoru: 0.0741 (En İyi Model)

Sonuç Yorumu: Yapılan testler sonucunda Random Forest algoritması rakiplerine göre daha yüksek başarımlar göstermiştir. Ancak genel skorun düşük olması, satış miktarının sadece fiyat ve markaya bağlı olmadığını; gün, saat, kampanya durumu gibi dış faktörlerin de etkili olduğunu göstermektedir. Gelecek çalışmalarda bu veriler eklenerek model geliştirilebilir.



6. Deployment (Dağıtım)

Bu model, marketin temel stok planlamasında bir baz (baseline) model olarak kullanılabilir.

Proje: Müşteri Segmentasyonu (Kümeleme Analizi)

Proje Konusu ve Veri Seti

Bu projede, marketteki müşteri davranışlarını anlamlandırmak için "MarketSales.xlsx" veri seti kullanılmıştır. Müşterilerin alışveriş alışkanlıklarını (fiyat ve miktar bazlı) gruplandırarak, benzer özellik gösteren müşteri profilleri oluşturulmuştur.

1. Business Understanding (İşin Anlaşılması)

Problem: Market müşterilerinin hepsi aynı değildir; kimisi tek bir ekmek alır, kimisi koliyle ürün alır. Herkese aynı pazarlama stratejisini uygulamak verimsizdir.

Hedef: Müşterileri alışveriş alışkanlıklarına (Fiyat ve Miktar) göre gruplara ayırarak, her gruba özel kampanya stratejileri geliştirmek.

2. Data Understanding (Verinin Anlaşılması)

Veri Seti: MarketSales verisi kullanılmıştır.

Öznitelikler: Analiz için PRICE (Birim Fiyat) ve AMOUNT (Satın Alınan Miktar) değişkenleri seçilmiştir.

Gözlem: Veri seti içerisinde hem perakende (az alım) hem de toptan (çoklu alım) işlemler olduğu gözlemlenmiştir.

3. Data Preparation (Veri Hazırlığı)

Örneklem: Veri seti çok büyük olduğu için 50.000 satırlık rastgele bir örneklem ile çalışılmıştır.


Ölçeklendirme: K-Means algoritması mesafelere duyarlı olduğu için, veriler StandardScaler kullanılarak standartlaştırılmıştır (Ortalama=0, Varyans=1).

4. Modeling (Modelleme & AutoML)

Algoritma: K-Means Clustering (K-Ortalamalar Kümeleme).

Optimizasyon: "Elbow Method" (Dirsek Yöntemi) kullanılarak 2 ile 18 arasındaki küme sayıları denenmiştir.

Model Seçimi: Hata kareler toplamı (Inertia) grafiğinde kırılma noktası incelenmiş ve en uygun küme sayısı (K) 3 olarak belirlenmiştir.



5. Evaluation (Değerlendirme)

Model sonucunda müşteriler 3 ana segmente ayrılmıştır:

Segment 0 (Standart Bireysel Müşteriler - Mor):

Özellik: Ortalama Fiyat: 2.47 TL, Ortalama Miktar: 1.33 Adet.

Yorum: Müşterilerin büyük çoğunluğunu oluşturan, günlük ucuz ürünlerden az miktarda alan gruptur.

Segment 1 (Toptancılar / Stokçular - Sarı):


Özellik: Ortalama Fiyat: 4.93 TL, Ortalama Miktar: 952.88 Adet.

Yorum: Bu grup sayıca az olsa da işlem hacmi çok yüksektir. Muhtemelen market, bakkal veya restoran işletmecileridir. Toplu alım yapmaktadırlar.

Segment 2 (Premium Müşteriler - Mavi/Yeşil):

Özellik: Ortalama Fiyat: 16.11 TL, Ortalama Miktar: 0.84 Adet.

Yorum: Adet olarak az alan ancak birim fiyatı yüksek, pahalı/lüks ürünleri tercih eden gruptur.



6. Deployment (Dağıtım)

Segment 0 İçin: "3 Al 2 Öde" gibi sepet büyötmeye yönelik kampanyalar yapılabilir.

Segment 1 İçin: Koli bazlı indirimler veya "Toptan Satış Kartı" sunulabilir.

Segment 2 İçin: Yeni gelen ithal/özel ürünlerin tanıtımı bu kitleye yapılabilir.

Segment		
0	2.636557	1.325588
1	5.500000	502.000000
2	16.111008	0.862345

Proje: Market Sepet Analizi (Birliktelik Kuralları)

Proje Konusu ve Veri Seti

Bu çalışmada, müşterilerin hangi ürünleri birlikte satın aldığını tespit etmek amacıyla "MarketSales.xlsx" veri seti üzerinden Apriori algoritması uygulanmıştır. Analiz, satış fişleri arasındaki gizli ilişkileri (Örn: Soğan alanın Patates alma eğilimi) ortaya çıkarmayı hedefler.

1. Business Understanding (İşin Anlaşılması)

Amaç: Müşterilerin alışveriş sepetlerinde hangi ürün kategorilerini birlikte tercih ettiklerini tespit etmek.

Hedef: Bu bilgiyi kullanarak market içi raf düzenini optimize etmek ve çapraz satış (cross-selling) fırsatları yaratmak.

2. Data Preparation (Veri Hazırlığı)

Veri setindeki CATEGORY_NAME1 (Ana Kategori) sütunu kullanılmıştır.

Veri, Apriori algoritmasının çalışabilmesi için "Sepet Matrisi" (Satırlarda Fiş No, Sütunlarda Kategoriler, Değerler 1/0) formatına dönüştürölmüştür.

3. Modeling (Modelleme)

Algoritma: Apriori Algoritması.

Parametreler: Veri setindeki çeşitlilik nedeniyle, anlamlı kuralları kaçırmamak adına Support (Destek) değeri 0.005 (%0.5) olarak belirlenmiş ve Lift (Kaldıraç) değeri > 1 olan kurallar filtrelenmiştir.

4. Evaluation (Değerlendirme)

Analiz sonucunda en güçlü ilişki Lift: 1.15 katsayısı ile [İÇECEK] ve [SÜT KAHVALTILIK] kategorileri arasında bulunmuştur.

Yorum: Bu iki kategorinin birlikte satılma ihtimali, tesadüfi birliktelikten %15 daha fazladır. Bu durum, müşterilerin kahvaltı alışverişlerinde içecekleri (meyve suyu, süt vb.) de sepete eklediğini göstermektedir.

5. Deployment (Dağıtım)

Kahvaltılık reyonunun hemen yanına veya karşısına içecek dolapları yerleştirilerek satış hacmi artırılabilir.

AutoML Başlıyor: En uygun destek (support) değeri aranıyor...
✓ Support=0.005 için 4 adet anlamlı kural bulundu!


🏆 EN GÜÇLÜ 5 KURAL (Seçilen Support: 0.005)

📖 EĞER [İÇECEK] ALINIRSA -> [SÜT KAHVALTILIK] ALINIYOR
(Güven: %20.2, Lift: 1.15 kat)

📖 EĞER [SÜT KAHVALTILIK] ALINIRSA -> [İÇECEK] ALINIYOR
(Güven: %3.5, Lift: 1.15 kat)

📖 EĞER [SÜT KAHVALTILIK] ALINIRSA -> [GIDA] ALINIYOR
(Güven: %47.5, Lift: 1.11 kat)

📖 EĞER [GIDA] ALINIRSA -> [SÜT KAHVALTILIK] ALINIYOR
(Güven: %1.4, Lift: 1.11 kat)



Proje: Market Verisi Anomali Tespiti (Outlier Detection)

Proje Konusu ve Veri Seti

Bu çalışmada, "MarketSales.xlsx" veri seti içerisinde yer alan hatalı, sıra dışı veya şüpheli işlemleri otomatik olarak tespit etmek amacıyla makine öğrenmesi teknikleri kullanılmıştır. Analiz, özellikle birim fiyat ve satış miktarı arasındaki uyumsuzlukları yakalamaya odaklanmıştır.

1. Business Understanding (İşin Anlaşılması)

Problem: Perakende satışlarda günde binlerce işlem gerçekleşmektedir. Kasa görevlilerinin yanlış tuşlama yapması (örn: 1 adet yerine 100 adet girmesi), sistemsal fiyat hataları veya şüpheli toplu alımlar manuel olarak takip edilemez.

Hedef: Makine öğrenmesi algoritmaları kullanarak, genel müşteri davranışına uymayan "uç değerleri" (outliers) otomatik tespit etmek ve olası cirosal kayıpları veya stok hatalarını önlemektir.

2. Data Understanding (Verinin Anlaşılması)

Veri Seti: MarketSales verisi kullanılmıştır.

Odak Değişkenler: Anomali tespiti için PRICE (Birim Fiyat) ve AMOUNT (Satış Miktarı) değişkenleri seçilmiştir.

Gözlem: Verinin %98'lik kısmı belirli bir fiyat ve miktar aralığında (Sol alt köşe) toplanırken, geri kalan kısmın çok dağınık ve uç noktalarda olduğu gözlemlenmiştir.

3. Data Preparation (Veri Hazırlığı)

Örneklem: Görselleştirme performansını artırmak ve modelin hızlı çalışması için veri setinden örneklem alınmıştır.

Ölçeklendirme: Uzaklık ve yoğunluk tabanlı algoritmalar (LOF gibi) ölçek farkından etkilenmemesi için veriler StandardScaler ile standartlaştırılmıştır (Ortalama=0, Varyans=1 formatına getirilmiştir).

4. Modeling (Modelleme & AutoML Yaklaşımı)

Yöntem: Hata payını düşürmek için tek bir algoritma yerine Ensemble (Topluluk) yaklaşımı kullanılmış ve iki farklı algoritma çalıştırılmıştır:

Isolation Forest (İzolasyon Ormanı): Veri noktalarını rastgele bölerek yalnız kalanları (anomalileri) tespit eder.

Local Outlier Factor (LOF): Veri noktalarının yoğunluğuna bakarak, komşularından kopuk olanları tespit eder.

Parametreler: Veri setindeki kirlilik/anomali oranı (contamination) %2 (0.02) olarak belirlenmiştir.

5. Evaluation (Değerlendirme)

Tespit Sayıları:

Isolation Forest Modeli: 199 adet şüpheli işlem.

Local Outlier Factor Modeli: 200 adet şüpheli işlem.

Grafik Yorumu: (Raporuna eklediğin grafiğe atıfta bulunarak)

Grafikteki Kırmızı Noktalar, modelin "Anomali" olarak etiketlediği işlemlerdir.

Bu noktalar incelendiğinde iki ana grup göze çarpmaktadır:

Miktar Anomalileri (Yatay Eksenin Sağı): Birim fiyatı düşük olsa da tek seferde aşırı yüksek adetli (örn: 50-100+ adet) yapılan satışlar.


Fiyat Anomalileri (Dikey Eksenin Üstü): Miktarı az olsa da fiyatı genel ortalamanın çok üzerinde olan işlemler.

Mavi Noktalar ise normal perakende alışveriş sınırları içinde kalan güvenli işlemlerdir.

6. Deployment (Dağıtım)

Geliştirilen model kasa yazılımına entegre edilebilir.

Aksiyon: Eğer bir işlem "Anomali" olarak sınıflandırılırsa, kasiyer ekranına "Dikkat: Bu işlemde alışılmadık miktar veya fiyat tespit edildi. Onaylıyor musunuz?" şeklinde bir uyarı penceresi çıkartılarak insan hatasının önüne geçilebilir.



--- TESPİT EDİLEN BAZI ŞÜPHELİ İŞLEMLER (ÖRNEK) ---

	PRICE	AMOUNT
37595	3.5	1.070
565353	4.5	0.926
69077	0.8	1.220
210835	3.1	1.055
418304	9.0	1.082